



**UNIVERSITÉ DE FIANARANTSOA
ÉCOLE NATIONALE D'INFORMATIQUE**

Mention : INTELLIGENCE ARTIFICIELLE

Parcours :

Intitulé :

**ANALYSE & OPTIMISATION MARKETING BASÉE SUR LA SEGMENTATION
CLIENT**

Présenté par le groupe :

* - N°
* - N°
* - N°

Année universitaire : -

Sommaire

1. Introduction et objectif du projet.....	3
2. Préparation des données.....	3
3. Exploration et comportement d'achat.....	3
4. Segmentation client.....	3
5. Performance des campagnes marketing.....	4
6. Prédiction du churn et de la valeur client (CLV).....	4
7. Stratégie marketing digitale personnalisée.....	5
8. Dashboard interactif.....	6
9. Conclusion et livrables.....	6

1. Introduction et objectif du projet

Ce rapport présente le travail réalisé dans le cadre du projet pédagogique « Analyse & Optimisation Marketing », qui vise à exploiter des données clients, produits, ventes et campagnes afin de segmenter la clientèle, comprendre les comportements d'achat, mesurer la performance des actions marketing et proposer une stratégie de personnalisation assistée par l'intelligence artificielle. La démarche suit la structure en modules (M1 à M9) fixée par l'énoncé du projet, et s'appuie sur quatre fichiers sources : customers_data.csv, sales_data.csv, products_data.csv et marketing_data.csv.

L'échantillon fourni est volontairement restreint (5 clients, 5 ventes, 5 produits, 5 campagnes), ce qui convient à un exercice pédagogique mais impose une lecture prudente des résultats : les tendances dégagées illustrent une méthode plutôt qu'elles ne constituent des conclusions statistiquement robustes. Cette limite est rappelée à chaque fois qu'elle est pertinente, plutôt que dissimulée.

2. Préparation des données

La préparation a porté sur trois points : la conversion des champs de date, la vérification des valeurs manquantes et le calcul du chiffre d'affaires de chaque vente (quantité × prix unitaire). Les quatre fichiers ont ensuite été rapprochés par jointure sur les identifiants client et produit afin de relier chaque transaction à un profil démographique et à une fiche produit.

Fichier source	Volume	Variables mobilisées
customers_data.csv	5 clients	Âge, sexe, localisation, dépense cumulée
sales_data.csv	5 ventes	Produit, client, quantité, prix, canal, date
products_data.csv	5 produits	Catégorie, prix, marque
marketing_data.csv	5 campagnes	Canal, budget, impressions, clics, conversions

3. Exploration et comportement d'achat

Les cinq ventes enregistrées représentent 9 unités vendues pour un chiffre d'affaires calculé de 475,00. La fusion ventes-clients-produits met en évidence des profils contrastés dans un échantillon aussi restreint : Alice réalise deux achats portant sur deux produits différents, ce qui en fait la cliente la plus active sur la période observée. Bob affiche la dépense cumulée la plus élevée du fichier clients (750), bien qu'une seule vente lui soit associée dans l'historique fourni. Eva, en revanche, figure dans la base clients sans qu'aucune vente ne lui soit rattachée : elle constitue une cible naturelle de réactivation, sous réserve de vérifier que l'historique transmis est bien complet.

4. Segmentation client

La segmentation repose sur un algorithme K-means à 3 groupes, appliqué après standardisation des variables suivantes : âge, dépense totale, nombre de commandes, quantité achetée, chiffre d'affaires observé et diversité des produits achetés. Avec seulement cinq clients, les groupes obtenus doivent être compris comme des profils illustratifs et non comme des segments validés statistiquement — une segmentation exploitable en production demanderait un historique nettement plus large.

Segment	Client(s)	Profil observé	Action recommandée
Forte valeur	Alice	Activité d'achat et valeur cumulée élevées	Fidélisation, offres premium, cross-sell
Intermédiaire	Bob, Diana	Dépense et fréquence d'achat moyennes	Bundles, recommandations ciblées
Faible activité	Charlie, Eva	Achat ponctuel ou absent sur la période	Relance e-mail / réseaux sociaux, offre de retour

5. Performance des campagnes marketing

Les cinq campagnes mobilisent un budget cumulé de 8 000, pour 200 000 impressions, 8 000 clics et 750 conversions. Le CTR global s'établit à 4,00 % et le taux de conversion (du clic à la conversion) à 9,38 %. Le canal In-Store affiche le meilleur taux de conversion (20,00 %), tandis que le canal Online présente le CPA le plus bas (6,67) et le canal Email le CTR le plus élevé (5,00 %).

Indicateur	Valeur	Meilleur canal	Valeur du canal
CTR global	4,00 %	Email	5,00 %
Taux de conversion (clic → conversion)	9,38 %	In-Store	20,00 %
CPA moyen	—	Online	6,67

Le retour sur investissement (ROI) n'a volontairement pas été calculé : les fichiers fournis ne permettent pas d'attribuer un chiffre d'affaires à chaque campagne. Le déduire uniquement du budget et du nombre de conversions aurait produit un chiffre trompeur ; il est préférable de signaler cette limite que de présenter un indicateur inventé.

6. Prédiction du churn et de la valeur client (CLV)

Le cahier des charges prévoit la construction d'un modèle prédictif (Random Forest, XGBoost ou régression logistique) pour anticiper le churn ou estimer la valeur vie client. Un pipeline complet a été construit (préparation des variables, régression logistique, validation leave-one-out) afin de répondre à cette demande — mais son résultat doit être lu avec une réserve méthodologique forte, détaillée ci-dessous plutôt que masquée.

Construction du proxy de churn et des variables

Les données fournies ne contiennent aucune variable de résiliation réelle. Un proxy a donc été défini par une règle métier : un client est considéré « churn = 1 » s'il n'a aucune vente enregistrée dans sales_data.csv sur la période observée. Ce proxy classe Eva en churn (aucun achat) et les quatre autres clients en non-churn. Les variables utilisées sont l'âge, la dépense totale déclarée, l'ancienneté (jours depuis inscription) et la récence (jours depuis le dernier achat, ou depuis l'inscription si aucun achat).

Modèle et validation

Une régression logistique a été entraînée sur les 5 clients, avec une validation leave-one-out (chaque client testé après entraînement sur les 4 autres). Sur ce très petit échantillon, la validation n'a pu être menée que sur 4 des 5 cas : l'exemple restant ne peut pas être évalué car son pli d'entraînement ne contient qu'une seule classe. Cette contrainte à elle seule illustre la limite : aucune métrique de performance (accuracy, précision, rappel) calculée sur un tel échantillon ne peut être considérée comme représentative d'une capacité de généralisation réelle.

Client	Churn proxy	Risque modèle	CLV historique	CLV projetée (12 mois)
Alice	0	5,0 %	500	683,52
Bob	0	5,4 %	750	1 185,06
Charlie	0	11,8 %	300	558,67
Diana	0	11,7 %	600	1 368,75
Eva	1	66,0 %	450	1 324,60

Les résultats restent néanmoins cohérents avec l'intuition métier : Eva, seule cliente sans vente enregistrée, obtient le risque de churn le plus élevé (66,0 %) loin devant les autres clients (5,0 % à 11,8 %). La CLV projetée à 12 mois (dépense actuelle extrapolée sur l'ancienneté du client) situe Diana et Bob au-dessus de 1 000, à nuancer eux aussi par le faible nombre d'observations disponibles.

Avertissement à conserver pour toute utilisation de ces résultats : ce modèle est un exercice pédagogique sur 5 lignes, pas un outil de décision commerciale. Le déployer en production sans un historique substantiellement plus large et une variable de churn réelle produirait des recommandations non fiables, malgré une apparence de rigueur technique.

Pour rendre ce module réellement opérationnel, il faudrait au minimum : un historique de transactions par client sur plusieurs périodes, une définition explicite et mesurée du churn (par exemple une absence d'achat pendant N jours), ainsi qu'une marge ou un revenu par client pour fiabiliser le calcul de la CLV.

7. Stratégie marketing digitale personnalisée

La stratégie proposée est directement adossée aux trois segments identifiés au point 4 :

- Forte valeur — programme de fidélité, recommandations de produits complémentaires, offres premium et communication personnalisée.
- Intermédiaire — bundles, remises conditionnelles, contenus pédagogiques sur les catégories pertinentes et relance après achat.
- Faible activité — retargeting e-mail et réseaux sociaux, offre de retour limitée dans le temps, rappel des avantages du programme.

L'intelligence artificielle générative peut accélérer la production de variantes de messages par segment (objet d'e-mail, accroche, visuel), à condition que les règles métier, la cohérence de marque et les indicateurs de performance restent sous contrôle humain avant diffusion.

8. Dashboard interactif

Un dashboard Streamlit (dossier dashboard/, fichier app.py) accompagne ce rapport. Il recalcule la segmentation en direct à partir de customers_data.csv et sales_data.csv, affiche les KPI de campagnes par canal, et présente les résultats du modèle churn/CLV avec l'avertissement de fiabilité repris directement à l'écran. Il se lance avec `pip install -r requirements.txt` puis `streamlit run app.py` ; le détail est donné dans le README.md du dossier.

9. Conclusion et livrables

Le projet couvre l'ensemble des modules M2 à M8 avec les données mises à disposition, y compris le module M6 (churn/CLV), traité avec un pipeline complet et un avertissement méthodologique explicite plutôt qu'un résultat présenté comme fiable sans nuance. La prochaine itération devrait porter en priorité sur l'élargissement du volume de données, sur une vraie variable de résiliation et sur l'ajout d'une attribution campagne → vente, condition nécessaire à un calcul de ROI et à une optimisation marketing complète.

Livrables produits :

- Segmentation client et profils détaillés
- Analyse des campagnes et recommandations
- Modèle exploratoire churn / CLV, avec avertissement de fiabilité
- Dashboard interactif Streamlit (dossier dashboard/)
- Rapport (Word/PDF) et présentation (PowerPoint)